Síntese de Fala em Português com Tacotron2-VAE: Estilo Copiado de um Áudio de Referência

Beatriz Nunes Herivelton Siqueira Richard Viana

Machine Learning II — IMPA Tech

Professores: Francisco Ganacim e Daniel Silveira Yukimura Lopez

Versão revisada — novembro de 2026

Resumo — Implementamos um sistema de síntese de fala baseado no Tacotron 2 com um *Variational Autoencoder* (VAE) que resume um áudio de referência em um vetor de estilo. Esta versão substitui a anterior, cujo resultado central ("atenção espectral interpretável") vinha de um erro de código e não era válido. Corrigimos o erro, passamos a treinar a partir de um Tacotron 2 pré-treinado e conferimos todo áudio gerado por reconhecimento de fala. A taxa de palavras erradas caiu de 68% para 2,2% em inglês e de ininteligível para 10,5% em português. Com o corpus emocional VERBO, a fala gerada copia a voz e o tom da referência, ao custo de inteligibilidade; um controle de intensidade do estilo recupera a inteligibilidade (9% de erro) mantendo parte da emoção. Página do projeto: `https://rick0110.github.io/ml2_final_project`.

1 Introdução

Sistemas de síntese de fala produzem fala inteligível, mas com entonação fixa. O Tacotron2-VAE [1, 2] comprime um **áudio de referência** em um vetor latente z que guarda o que o texto não determina (tom, velocidade, voz) e condiciona a síntese: o texto diz o que falar, a referência diz como. Nosso objetivo é ter esse sistema funcionando em português, como primeira peça de um sistema de dublagem.

2 Revisão da versão anterior

A versão anterior deste relatório propunha um *pooling* por atenção no *reference encoder* e interpretava seus pesos como bandas do espectro. A revisão do código mostrou três problemas. (i) O mel de formato $(B, 80, T)$ era reorganizado com `view` sem transpor os eixos: tempo e frequência ficavam misturados e a posição dos blocos mudava com o *padding* do lote. As "bandas" eram efeito desse erro. (ii) A comparação com o *baseline* usava treinos de 11,2 mil e 35,5 mil iterações, e não sustentava a conclusão sobre o colapso do latente. (iii) Os áudios eram pouco inteligíveis: transcritos pelo Whisper [10], os 26 áudios em inglês tinham em média 68% das palavras erradas e os dois em português não eram reconhecidos. Uma `LayerNorm` extra na atenção do decoder ainda impedia o uso de pesos pré-treinados. Todos os resultados abaixo são da versão corrigida.

3 Arquitetura

O sistema (Fig. 1) segue o Tacotron 2 [3, 4]: um *encoder* de texto (embedding + 3 Conv1d + BiLSTM), uma atenção sensível à localização, um decoder autoregressivo que prevê o mel quadro a quadro e o sinal de parada, e o vocoder **HiFi-GAN** universal [5], pré-treinado e congelado. O inglês entra como caracteres e o português como fonemas IPA; os dois conjuntos ficam na mesma tabela de 199 símbolos, o que permite ajustar para o português um modelo treinado em inglês.

O *reference encoder* [6] aplica 6 convoluções 2D de *stride* 2 ao mel de referência e uma GRU sobre os $T/64$ blocos de tempo resultantes ($\sim$0,74 s cada). Os estados h_t são resumidos por atenção, $e = \sum_t \alpha_t h_t$ com $\alpha = \mathrm{softmax}(w^\top h_t + b)$, com peso zero nos blocos de *padding*. O resumo é projetado em (μ, σ); amostra-se z de 32 dimensões, convertido em um vetor de estilo somado a todas as posições da saída do *encoder*. Não comparamos esse resumo com o último estado da GRU, e por isso não afirmamos que seja melhor.

4 Treinamento

A perda combina quatro termos:

$$\mathcal{L} = \mathcal{L}_{\text{mel}} + \mathcal{L}_{\text{gate}} + \beta(\text{passo})\,\mathcal{L}_{\text{KL}} + \lambda\,\mathcal{L}_{\text{GA}},$$

com MSE do mel, entropia cruzada do sinal de parada, KL com *free bits* de 0,5 e β cíclico (0 a 0,2), e atenção guiada [7]. Treinar do zero não cabia no orçamento e era a causa provável dos alinhamentos ruins; por isso o treino é feito em etapas, cada uma partindo da anterior (Tab. 1), em uma GPU L4, com Adam ($lr = 10^{-4}$) e 28,9 M de parâmetros.

Etapa	Dados	Passos
Inglês	LJSpeech, 23,7 h	2.500
Português	TTS-Portuguese [8], 3,8 h	4.000
Emoção	TTS-Port. + VERBO [9]	1.500

Table 1: Etapas de treino. A primeira parte do Tacotron 2 pré-treinado da NVIDIA; cada uma das seguintes parte da anterior. O VERBO tem 1.167 falas de 12 locutores em 7 emoções, com apenas 14 frases distintas.

5 Avaliação

Para cada modelo sintetizamos 6 frases fora do treino com várias referências. Cada áudio é transcrito pelo Whisper *small* e comparado com o texto pedido (taxa de palavras erradas, WER). Medimos também se o decoder para sozinho, o tom médio (F0) e a velocidade (caracteres por segundo) do áudio gerado e da referência.

Inglês. WER de 2,2% em 18 áudios, todos terminando sozinhos; os três erros são a mesma palavra ("stone"). Tom e velocidade não acompanharam as referências: o LJSpeech é uma locutora com leitura uniforme, e há pouca variação de estilo a aprender.

Português. WER de 10,5% em 18 áudios, todos terminando sozinhos (Fig. 3). Os erros são trocas pontuais

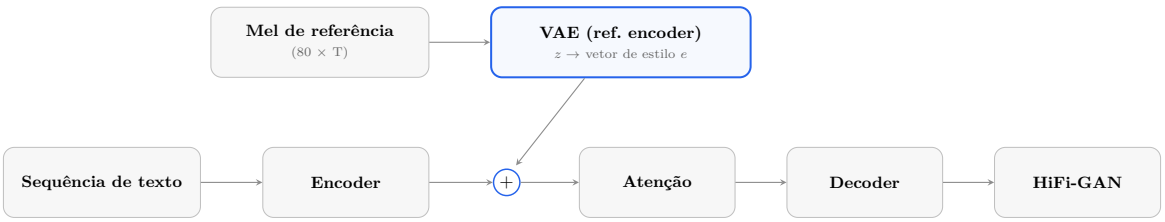


Figura 1: Arquitetura do sistema: o VAE comprime o Mel de referência no vetor de estilo e, somado (+) a cada posição da memória do *encoder*; atenção e decoder geram o Mel-espectrograma, convertido em áudio pelo HiFi-GAN.

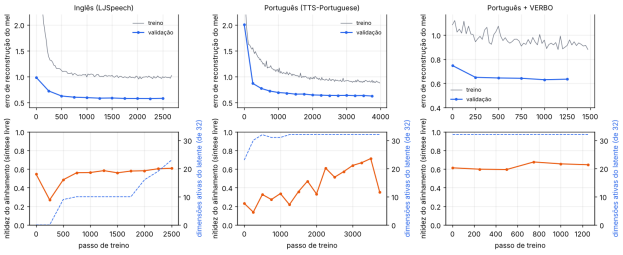


Figura 2: Em cima: erro de reconstrução do mel (treino em cinza, validação em azul; o treino é maior porque metade dos quadros de entrada do decoder é descartada). Embaixo: nitidez do alinhamento na síntese livre (laranja) e dimensões ativas do latente (tracejado).

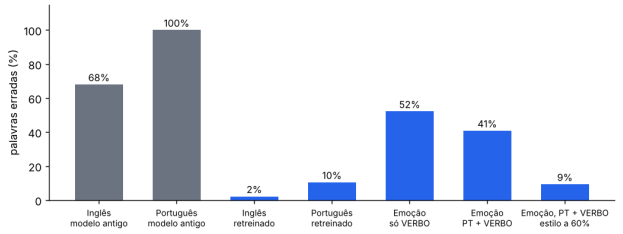


Figura 3: Palavras erradas na transcrição automática dos áudios gerados. Cinza: modelos anteriores. Azul: retreinados.

("carrega"→"cariga"). A velocidade da fala acompanha a referência: com referências de 9,1, 12,6 e 16,3 caracteres/s, a mesma frase saiu com 8,8, 11,9 e 12,7. As 32 dimensões do latente ficam ativas (Fig. 2).

Emoção. Usamos 10 referências do VERBO (7 emoções da locutora f1 e 3 do locutor m1). O modelo de português, sem ver o VERBO, mantém a própria voz (WER 19%, sem relação entre o tom gerado e o da referência). Ajustado só no VERBO, o modelo copia voz e tom (correlação 0,96 entre o F0 gerado e o da referência), mas o WER sobe para 52%: com 14 frases, ele desaprende a ler texto novo. Treinando com os dois corpora juntos, o tom continua seguindo a referência (correlação 0,97, Fig. 4) e o WER cai para 41%, ainda alto.

Intensidade do estilo. O erro vem de sintetizar com vozes que o modelo só ouviu em 14 frases. Multiplicando o código latente da referência por um fator $a \in [0, 1]$ antes da síntese, $z = a\,\mu_{\text{ref}}$, obtemos um controle contínuo (Fig. 5): com $a = 0{,}6$ o WER cai para 9% e a velocidade ainda varia com a emoção (de 9,3 a 14,1 caracteres/s), mas o tom fica próximo do neutro. Emoção forte e fala clara não foram obtidas ao mesmo tempo; o limite está no corpus, não no modelo.

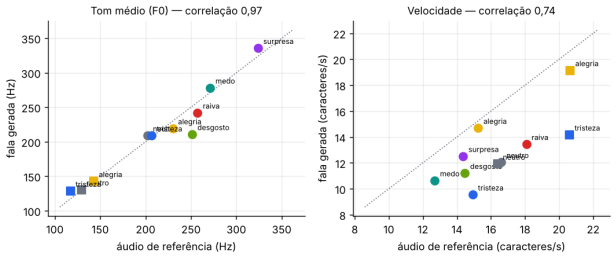


Figura 4: Modelo português + VERBO, estilo inteiro: tom e velocidade da fala gerada contra os da referência (círculos: locutora f1; quadrados: locutor m1).

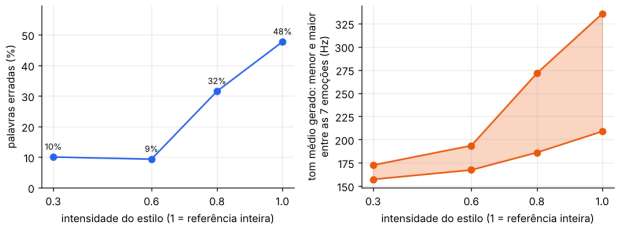


Figura 5: Efeito da intensidade do estilo (7 emoções da locutora f1): palavras erradas e faixa do tom médio entre as emoções.

6 Conclusão

O resultado central da versão anterior era um erro e foi retirado. Com o código corrigido e o treino a partir de um modelo pré-treinado, o sistema fala inglês e português de forma inteligível e copia da referência a velocidade e, com dados de vários locutores e emoções, a voz e o tom. Com o VERBO, copiar a emoção por inteiro custa inteligibilidade, e o controle de intensidade do estilo permite escolher o ponto desse compromisso. Limitações: a avaliação usa poucas frases e mede só inteligibilidade, não naturalidade; o vetor de estilo é global e não varia ao longo da frase; o *pooling* por atenção não foi comparado com a alternativa mais simples. Para a dublagem faltam o controle de duração das falas, o vídeo como entrada e a sincronia labial.

Referências

[1] Hsu, W.-N. et al. *Hierarchical Generative Modeling for Controllable Speech Synthesis*. ICLR, 2019.

[2] Zhang, Y.-J., Pan, S., He, L., Ling, Z.-H. *Learning Latent Representations for Style Control and Transfer in End-to-End Speech Synthesis*. ICASSP, 2019. arXiv:1812.04342.

[3] Shen, J. et al. *Natural TTS Synthesis by Conditioning WaveNet on Mel Spectrogram Predictions*. ICASSP, 2018. arXiv:1712.05884.

[4] NVIDIA. *Tacotron 2* (implementação de referência). https://github.com/NVIDIA/tacotron2.

[5] Kong, J., Kim, J., Bae, J. *HiFi-GAN: Generative Adversarial Networks for Efficient and High Fidelity Speech Synthesis*. NeurIPS, 2020.

[6] Skerry-Ryan, R.J. et al. *Towards End-to-End Prosody Transfer for Expressive Speech Synthesis with Tacotron*. ICML, 2018.

[7] Tachibana, H. et al. *Efficiently Trainable Text-to-Speech System Based on Deep Convolutional Networks with Guided Attention*. 2017.

[8] Casanova, E. et al. *TTS-Portuguese Corpus: a corpus for speech synthesis in Brazilian Portuguese*. Language Resources and Evaluation, 2022.

[9] Torres Neto, J. R. et al. *VERBO: Voice Emotion Recognition dataBase in Portuguese Language*. Journal of Computer Science, 2018.

[10] Radford, A. et al. *Robust Speech Recognition via Large-Scale Weak Supervision*. ICML, 2023.