Síntese de Fala com Tacotron2-VAE: Atenção Temporal Interpretável no *Reference Encoder*

Beatriz Nunes Herivelton Siqueira Richard Viana

Machine Learning II — IMPA Tech

Professores: Francisco Ganacim e Daniel Silveira Yukimura Lopez

Julho de 2026

Resumo — Implementamos um sistema de síntese de fala (*Text-to-Speech*) baseado no Tacotron2 com um *Variational Autoencoder* (VAE) para modelagem de prosódia. A contribuição central do trabalho é substituir o *pooling* usual do *reference encoder* (último estado da GRU) por um *pooling* por **atenção temporal**, tornando o condicionamento de estilo interpretável, além de produzir um modelo especificamente para o português a partir do corpus emocional VERBO. Treinamos três modelos — *baseline* e variante com atenção no LJSpeech (inglês), e a variante em português no VERBO — e avaliamos transferência de estilo e de emoção, interpretabilidade dos pesos de atenção, manipulação direta do espaço latente e interpolação esférica (*slerp*) versus linear (*lerp*). Página do projeto: https://rick0110.github.io/ml2_final_project.

1 Introdução

Sistemas de TTS tradicionais produzem fala inteligível, porém com entonação pouco natural. O Tacotron2-VAE [1, 2] ataca esse problema comprimindo um **áudio de referência** em um vetor latente z que captura características globais de estilo (ritmo, tom, velocidade) e condiciona a síntese. Na prática, contudo, esse latente frequentemente "morre": o modelo aprende a reconstruir o espectrograma ignorando z (*posterior collapse*). Este trabalho, então, implementa métodos para evitar o colapso e investiga uma mudança estrutural simples no *reference encoder* — atenção temporal em vez do último estado da GRU — para tornar o latente informativo e interpretável, respectivamente. Em paralelo, tivemos problemas de alinhamento na atenção do decoder e por isso introduzimos a perda de atenção guiada, ausente no artigo de referência [2].

2 Arquitetura

O sistema (Fig. 1) segue o Tacotron2 [3, 4] em quatro passos: (i) um *text encoder* (embedding de símbolos + 3 camadas Conv1d + BiLSTM) extrai representações linguísticas; (ii) uma atenção sensível à localização alinha texto e áudio no decoder; (iii) um decoder autoregressivo prevê o Mel-espectrograma quadro a quadro; (iv) o vocoder **WaveGlow** [5] (pré-treinado e congelado) converte o espectrograma em forma de onda.

Em paralelo, o *reference encoder* processa o Mel-espectrograma de referência com 6 convoluções 2D de *stride* 2 (a primeira é uma CoordConv), reduzindo $80\times T$ para $\sim 128\times(T/64)$, seguidas de uma GRU. O resultado é projetado nos parâmetros (μ, σ) do posterior; amostra-se z (32 dims no LJ, 16 no VERBO), que é convertido em um vetor de estilo somado a todas as posições da memória do *text encoder*.

3 A mudança: atenção temporal

No *baseline* [6], o resumo do áudio de referência é apenas o **último estado da GRU** — um vetor opaco, no qual o gradiente favorece as janelas finais. Propomos um *pooling* por atenção sobre todos os estados h_t:

$$s_t = w^\top h_t + b, \qquad \alpha = \mathrm{softmax}(s), \qquad e = \textstyle\sum_t \alpha_t h_t,$$

implementado com uma camada linear de *score* e um softmax no tempo ($E/2 + 1$ parâmetros). Os ganhos são dois: o gradiente flui para **todas** as janelas temporais ($\sim$0,74 s cada), e os pesos α_t formam um mapa de atenção legível — sabemos *quais trechos* do áudio de referência definem o estilo.

4 Dados e pré-processamento

Foram usados dois corpora: **LJSpeech 1.1** (13.100 falas, $\sim$23,9 h, locutora única, inglês) e **VERBO** (locutora f1: 98 falas, $\sim$4,7 min, português, 7 emoções). Todo áudio é reamostrado para 22.050 Hz e convertido em Mel-espectrogramas de 80 canais (FFT 1024, *hop* 256, $f_{\max} = 8$ kHz). O texto usa *english_cleaners* (caracteres) no LJ e fonemas IPA via *gruut* no VERBO.

5 Treinamento

A perda total combina quatro termos:

$$\mathcal{L} = \mathcal{L}_{\text{mel}} + \mathcal{L}_{\text{gate}} + \beta(\text{passo})\,\mathcal{L}_{\text{KL}} + \lambda\,\mathcal{L}_{\text{GA}},$$

onde $\mathcal{L}_{\text{mel}}$ é o MSE de reconstrução (decoder + postnet, mascarado no *padding*), $\mathcal{L}_{\text{gate}}$ é a entropia cruzada do sinal de parada, $\mathcal{L}_{\text{KL}}$ é a divergência KL com *free bits* de 0,5 e $\mathcal{L}_{\text{GA}}$ é a perda de **atenção guiada** [7], que penaliza massa de atenção longe da diagonal e resolve o desalinhamento severo do início do treino (LJ: $\lambda = 2{,}0$, $\sigma = 0{,}4$; VERBO: $\lambda = 50$, $\sigma = 0{,}2$, um prior forte para o corpus minúsculo). O *KL annealing* é cíclico (β em rampa de 0 a 0,2 a cada 4.000 passos), mitigando o *KL vanishing*. Otimização com Adam ($lr = 10^{-4}$); três modelos (Fig. 2): LJ *baseline* (11,2 mil iterações), LJ atenção (35,5 mil) e VERBO (9,5 mil), com 28,9M e 7,7M parâmetros.

6 Resultados e experimentos

Transferência de estilo (LJSpeech). Sintetizamos duas frases condicionadas a três referências de prosódia contrastante: grave/lenta (F0 173 ± 57 Hz; 10,1 caract./s), expressiva e rápida (19,2 caract./s). O *baseline* produz áudios praticamente idênticos entre referências; o modelo com atenção muda ritmo e F0 de forma audível e consistente com a referência.

Interpretabilidade da atenção. No LJ, os pesos

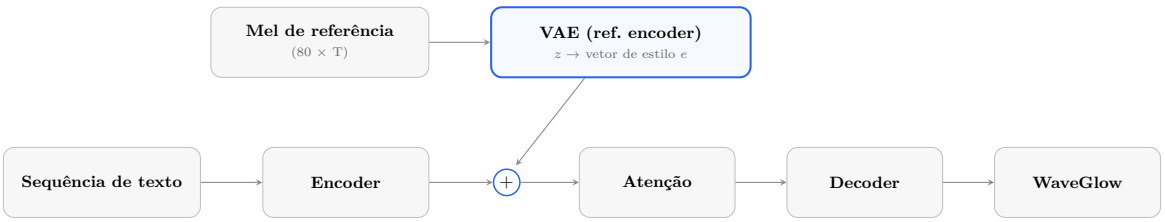


Figura 1: Arquitetura do sistema: o VAE comprime o Mel de referência no vetor de estilo e, somado (+) a cada posição da memória do *encoder*; atenção e decoder geram o Mel-espectrograma, convertido em áudio pelo WaveGlow.

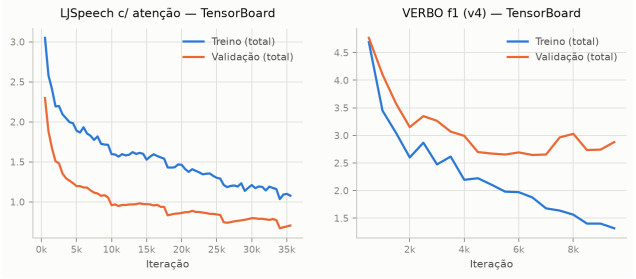


Figura 2: Perda total (treino vs. validação): *overfitting* esperado no VERBO, com só 98 falas.

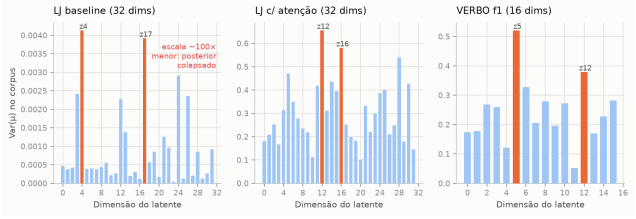


Figura 3: Variância de μ por dimensão do latente: posterior colapsado no *baseline* (escala ∼100× menor); com atenção, 32/32 (LJ) e 15/16 (VERBO) dimensões ativas.

α_t são não-uniformes e privilegiam regiões vozeadas com F0 marcado (Fig. 4). No VERBO, a **entropia normalizada** da atenção correlaciona-se com a emoção da referência: alegria 0,99, raiva 0,99 e surpresa 0,98 (atenção quase uniforme — pistas espalhadas) contra tristeza 0,67, neutro 0,70 e desgosto 0,76 (atenção concentrada, tipicamente no final). A correlação com a energia do sinal é fraca ($|r| \leq 0{,}38$): a atenção não é um mero detector de volume.

Transferência de emoção em português. Condicionando a síntese às 7 referências emocionais do VERBO, ritmo e registro mudam consistentemente com a emoção. Limitações: ∼4,7 min de dados e vocoder treinado em inglês geram artefatos — o objetivo é estudar o espaço de estilo, não produção.

Manipulação direta do latente. Movendo uma única dimensão influente a $\pm 3\sigma$ (referência fixa), os modelos com atenção produzem mudanças *graduais e audíveis* de ritmo/registro; no *baseline*, $\pm 3\sigma$ de uma dimensão morta ($\sigma \approx 0{,}06$) não muda nada.

Interpolação: esfera, não reta. Em alta dimensão, a massa do prior gaussiano concentra-se numa casca de raio $\sqrt{L}$. A *lerp* entre dois códigos ($\theta = 80°$ no LJ atenção) atravessa o interior da casca e em $t = 0{,}25$–$0{,}50$ o áudio perde definição harmônica (espectros "lavados"); a *slerp* [8] caminha pelo arco e preserva a qualidade em todo o caminho. No *baseline* ($\theta = 14°$), *lerp* e *slerp* coincidem — o caso degenerado.

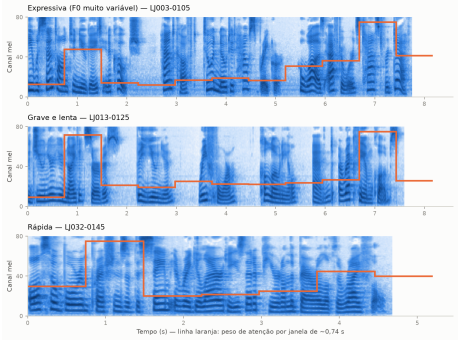


Figura 4: Pesos de atenção temporal (linha laranja, janelas de ∼0,74 s) sobre o Mel-espectrograma de três referências do LJSpeech.

7 Conclusão

A troca do *pooling* do *reference encoder* por atenção temporal foi suficiente para tornar o modelo interpretável, e a introdução da perda de alinhamento sobre a atenção sensível à localização tornou o treinamento mais estável e robusto contra o desalinhamento temporal da fala. Os pesos de atenção são interpretáveis e seguem padrões previsíveis por emoção; a geometria esférica do prior deve ser respeitada (*slerp* > *lerp*). Continuação natural: corpora maiores de português e um modelo não autoregressivo capaz de operar em tempo real.

Referências

[1] Hsu, W.-N. et al. *Hierarchical Generative Modeling for Controllable Speech Synthesis*. ICLR, 2019.

[2] Zhang, Y.-J., Pan, S., He, L., Ling, Z.-H. *Learning Latent Representations for Style Control and Transfer in End-to-End Speech Synthesis*. ICASSP, 2019. arXiv:1812.04342.

[3] Shen, J. et al. *Natural TTS Synthesis by Conditioning WaveNet on Mel Spectrogram Predictions*. ICASSP, 2018. arXiv:1712.05884.

[4] NVIDIA. *Tacotron 2* (implementação de referência). https://github.com/NVIDIA/tacotron2.

[5] NVIDIA. *WaveGlow* (código e *checkpoint* LJS 256 canais). https://github.com/NVIDIA/waveglow; https://catalog.ngc.nvidia.com/orgs/nvidia/models/waveglow_ljs_256channels.

[6] Skerry-Ryan, R.J. et al. *Towards End-to-End Prosody Transfer for Expressive Speech Synthesis with Tacotron*. ICML, 2018.

[7] Tachibana, H. et al. *Efficiently Trainable Text-to-Speech System Based on Deep Convolutional Networks with Guided Attention*. 2017.

[8] White, T. *Sampling Generative Networks*. 2016.